

Universidad Nacional de Colombia

Departamento de Estadística

Taller de repaso para el primer examen

2018631 Teoría de muestreo; 2020928 Muestreo estadístico aplicado; 2016369 Muestreo estadístico

Profesor: Giovany Babativa-Márquez, PhD.

Temas del examen 1: conceptos básicos, diseño muestral, probabilidades de inclusión, π -estimador de Horvitz-Thompson, M.A.S, muestreo Bernoulli, confiabilidad, tamaño de muestra, muestreo con reemplazo (estimador MCR de Hansen-Hurwitz) y estimación para dominios.

Datos: los archivos referenciados se encuentran en la carpeta **data** del repositorio.

1. (**Adaptado de Lohr, 2022, Cap. 1**) Para cada una de las siguientes encuestas, describa la población objetivo, el marco de muestreo, la unidad de muestreo y la unidad de observación.
 - a. Un estudiante desea estimar el porcentaje de fondos cuyas acciones aumentaron de precio la semana pasada. Usando una lista que salió en el periódico *Portafolio*, el alumno eligió uno de cada 10 fondos y con estos calculó el porcentaje de aquellos donde el precio de la acción había aumentado.
 - b. Se extrae una muestra de 8 arquitectos de una ciudad con 45 arquitectos. Para formar la muestra de la encuesta, cada arquitecto fue contactado por teléfono por orden de aparición en el directorio telefónico. Los primeros ocho que acordaron ser entrevistados conformaron la muestra.
 - c. Para estimar cuántos libros de la biblioteca deben ser encuadernados de nuevo, un bibliotecario utiliza una tabla de números aleatorios para elegir al azar 100 posiciones en los estantes de la biblioteca. Luego, camina hasta cada posición, busca el libro que se encuentra en ese punto y registra si el libro debe encuadernarse o no.
 - d. Se realiza un estudio para determinar el peso promedio de las vacas en una región del país. Usando una lista de las granjas de la región, se eligen 50 de ellas. Luego se registra el peso de cada vaca de las 50 granjas elegidas.
 - e. En un juicio sobre marcas registradas, un demandante que afirme que otra compañía infringe sus marcas debe mostrar con frecuencia que las marcas tienen un *significado secundario* en el mercado; es decir, los usuarios potenciales del producto asocian las marcas registradas con el demandante aún cuando no esté presente el nombre de la compañía. Estos estudios son denominados de *confusión de marca*. Un estudio de confusión de marca entre los empaques de *Something Special* y *Haig Supreme*, aplicado con una encuesta realizada a 500 personas consumidoras de whisky, mostró que cuando se mostraba la botella de *Haig Supreme* (sin etiqueta) más del 50 % de los consumidores lo asociaron con *Something Special*.
2. Considere un marco de lista de N familias. Si se extrae una muestra de tamaño n aplicando M.A.S, calcule la probabilidad de que:
 - a. La familia k quede incluida en la muestra.
 - b. Las familias k y l queden incluidas en la muestra.
 - c. Las familias k , l y m queden incluidas en la muestra.
 - d. ¿Cuál es la probabilidad de selección de la familia k ?
3. (**Lohr, 2022, Ej. 2.1**) Sean $N = 6$ y $n = 3$. Para estudiar las distribuciones muestrales suponga que se conocen todos los valores de la variable de interés en la población:

$$\begin{array}{lll} y_1 = 98 & y_2 = 102 & y_3 = 154 \\ y_4 = 133 & y_5 = 190 & y_6 = 175 \end{array}$$

El parámetro de interés es $\bar{y}_U$, la media de la población. Se proponen dos planes de muestreo:

Plan 1: ocho muestras posibles

Muestra	s	$p(s)$
1	$\{1, 3, 5\}$	$1/8$
2	$\{1, 3, 6\}$	$1/8$
3	$\{1, 4, 5\}$	$1/8$
4	$\{1, 4, 6\}$	$1/8$
5	$\{2, 3, 5\}$	$1/8$
6	$\{2, 3, 6\}$	$1/8$
7	$\{2, 4, 5\}$	$1/8$
8	$\{2, 4, 6\}$	$1/8$

Plan 2: tres muestras posibles

Muestra	s	$p(s)$
1	$\{1, 4, 6\}$	$1/4$
2	$\{2, 3, 6\}$	$1/2$
3	$\{1, 3, 5\}$	$1/4$

- ¿Cuál es el valor de $\bar{y}_U$?
 - Sea $\bar{y}_s$ la media de los valores de la muestra. Para cada plan de muestreo, determine: (i) $E(\bar{y}_s)$; (ii) $V(\bar{y}_s)$; (iii) $B(\bar{y}_s)$; (iv) $ECM(\bar{y}_s)$.
 - Entre los dos planes de muestreo, ¿cuál es el mejor y por qué?
4. (**Adaptado de Lohr, 2022, Ej. 2.2**) Sean $N = 8$ y $n = 4$. Suponga que los valores de la variable de interés son

$$\begin{array}{cccc} y_1 = 98 & y_2 = 102 & y_3 = 154 & y_4 = 133 \\ y_5 = 190 & y_6 = 175 & y_7 = 185 & y_8 = 105 \end{array}$$

Considere el siguiente diseño muestral:

s	$p(s)$
$\{1, 3, 5, 6\}$	$1/8$
$\{2, 3, 7, 8\}$	$1/4$
$\{1, 4, 6, 8\}$	$1/8$
$\{2, 4, 6, 8\}$	$3/8$
$\{4, 5, 7, 8\}$	$1/8$

- Determine la probabilidad de inclusión π_k para cada elemento.
 - ¿Cuál es la distribución muestral de $\hat{t}_{y,\pi}$?
 - ¿Cuál es la distribución muestral de $\bar{y}_s$?
5. (**Särndal et al., 1992, Ej. 2.3**) Considere una población U compuesta por tres subpoblaciones disjuntas U_1 , U_2 y U_3 de tamaños $N_1 = 600$, $N_2 = 300$ y $N_3 = 100$, respectivamente. Así, U es de tamaño $N = 1000$. Para cada elemento $k \in U$, la inclusión o no inclusión en la muestra s se determina mediante un experimento Bernoulli que le da al elemento k la probabilidad π_k de ser seleccionado. Los experimentos son independientes.
- Sea $\pi_k = 0,1$ para todo $k \in U_1$, $\pi_k = 0,2$ para todo $k \in U_2$ y $\pi_k = 0,8$ para todo $k \in U_3$. Encuentre el valor esperado y la varianza del tamaño de muestra n_s bajo este diseño.
 - Suponga que π_k es constante para todo $k \in U$. Determine esta constante de tal manera que el valor esperado del tamaño de muestra coincida con el obtenido en el literal a. Obtenga la varianza del tamaño de muestra y compárela con la varianza del literal a.
6. (**Särndal et al., 1992, Ej. 2.5**) Considere una población de tamaño $N = 3$, $U = \{1, 2, 3\}$. Sean $s_1 = \{1, 2\}$, $s_2 = \{1, 3\}$, $s_3 = \{2, 3\}$, $s_4 = \{1, 2, 3\}$, con $p(s_1) = 0,4$, $p(s_2) = 0,3$, $p(s_3) = 0,2$ y $p(s_4) = 0,1$.
- Calcule todos los π_k y todos los π_{kl} .
 - Encuentre el valor de $E(n_s)$ de dos formas: (i) por cálculo directo usando la definición, y (ii) usando la fórmula que expresa a $E(n_s)$ como función de los π_k .
7. (**Särndal et al., 1992, Ej. 2.6**) Considere la población y el diseño del ejercicio anterior. Sean los valores de la variable de estudio $y_1 = 16$, $y_2 = 21$ y $y_3 = 18$, de modo que $t_y = 55$.

- a. Usando la definición de valor esperado y varianza, calcule el valor esperado y la varianza del π -estimador $\hat{t}_{y,\pi}$.
- b. Calcule la varianza del π -estimador usando la fórmula

$$V(\hat{t}_{y,\pi}) = \sum_U \sum_{kl} \Delta_{kl} \frac{y_k}{\pi_k} \frac{y_l}{\pi_l}.$$

- c. Calcule el coeficiente de variación del π -estimador.
- d. Calcule la varianza estimada

$$\hat{V}(\hat{t}_{y,\pi}) = \sum_s \sum_{kl} \frac{\Delta_{kl}}{\pi_{kl}} \frac{y_k}{\pi_k} \frac{y_l}{\pi_l}$$

para cada una de las cuatro muestras posibles. Determine el valor esperado de este estimador de varianza usando la definición de valor esperado. ¿Es un estimador insesgado de la varianza real?

8. (Lohr, 2022, Ej. 2.15) Mayr et al. (1994) tomaron una muestra M.A.S de $n = 240$ niños entre 2 y 6 años que visitaron su consulta pediátrica y encontraron la siguiente distribución de frecuencias para la variable *edad (en meses) en que el niño empezó a caminar sin ayuda*:

Edad (meses)	9	10	11	12	13	14	15	16	17	18	19	20
Número de niños	13	35	44	69	36	24	7	3	2	5	1	1

- a. Construya un histograma de la distribución de la edad al comenzar a caminar. ¿Cree usted que la variable sigue una distribución normal? ¿La distribución muestral de la edad promedio en que los niños comienzan a caminar sigue una distribución normal? Explique.
 - b. Determine la media $\bar{y}_s$, el coeficiente de variación estimado y un intervalo de confianza del 95 % para la edad promedio en que los niños comienzan a caminar solos.
 - c. Suponga que se desea hacer otro estudio en una región diferente y que el intervalo de confianza del 95 % para la edad promedio en que los niños comienzan a caminar solos tenga un margen de error de 0,5 meses. Basándose en la información auxiliar proporcionada por esta muestra, ¿qué tamaño de muestra se necesitaría usando un diseño M.A.S?
9. (Lohr, 2022, Ej. 2.7) Una carta publicada en una revista de pasatiempos indicaba lo siguiente: “*He observado que en los últimos números no hay ganadores del sur en los concursos. Ustedes siempre dicen que los ganadores se eligen al azar. ¿Significa esto que ustedes reciben menos participaciones del sur?*”. En respuesta, los editores tomaron una muestra aleatoria de 1 000 participaciones de los últimos concursos y encontraron que 175 provenían del sur.
 - a. Determine un intervalo de confianza del 95 % para el porcentaje de participaciones provenientes del sur.
 - b. De acuerdo con el censo, el 30,9 % de la población vive en los estados que los editores consideraron del sur. ¿Hay alguna evidencia en el intervalo de confianza de que el porcentaje de participaciones del sur difiere del porcentaje de personas que viven en esa región del país?
 10. (Lohr, 2022, Ej. 2.10) ¿Cuál de los siguientes diseños M.A.S proporciona mayor precisión para estimar una media poblacional? Suponga que las tres poblaciones tienen la misma varianza poblacional S_{yU}^2 . Justifique su respuesta.
 - a. Una M.A.S de tamaño $n = 400$ de una población de tamaño $N = 4000$.
 - b. Una M.A.S de tamaño $n = 30$ de una población de tamaño $N = 300$.
 - c. Una M.A.S de tamaño $n = 3000$ de una población de tamaño $N = 300\,000\,000$.
 11. (Lohr, 2022, Ej. 2.23) La base de datos de delitos conocidos por la policía de Chicago entre 2001 y 2019 (<https://data.cityofchicago.org/>) contenía $N = 7\,048\,107$ registros. Para reducir el tamaño de los datos al realizar los análisis, se extrajo una muestra M.A.S de 5 000 registros, la cual se encuentra en el archivo `data/crimes.csv`.
 - a. ¿Cuál es el factor de expansión de cada registro de la muestra?

- b. ¿Cuál es el porcentaje estimado de delitos en los que se realizó un arresto (variable **arrest**)? Construya un intervalo de confianza del 95 %.
- c. Estime el número total de robos con allanamiento (*burglaries*) conocidos por la policía entre 2001 y 2019 (use la variable **crimetype** para identificarlos), junto con un intervalo de confianza del 95 %.
- d. ¿Qué porcentaje de los delitos estuvo relacionado con violencia doméstica (variable **domestic**)? ¿Cuál es el coeficiente de variación estimado (*cve*) de la estimación?
12. (**Adaptado de Lohr, 2022, Ej. 2.24**) Suponga una población artificial donde se conocen todos los valores de y_k para cada una de las $N = 8$ unidades de la población. Sea $U = \{1, 2, 3, 4, 5, 6, 7, 8\}$ y $y_k = \{20, 32, 16, 27, 15, 22, 18, 31\}$. Usando el procedimiento ilustrado en clase, para el intervalo de confianza

$$IC(s) = \left[\hat{t}_{y,\pi} - 1,96\sqrt{V(\hat{t}_{y,\pi})}, \hat{t}_{y,\pi} + 1,96\sqrt{V(\hat{t}_{y,\pi})} \right]$$

- a. Determine la confiabilidad exacta del intervalo basado en una M.A.S de tamaño $n = 4$. ¿Es igual al 95 % la confiabilidad?
- b. En la práctica la varianza es desconocida y debe ser estimada. Si en la fórmula del intervalo de confianza el término $V(\hat{t}_{y,\pi})$ es sustituido por $\hat{V}(\hat{t}_{y,\pi})$, determine la confiabilidad del intervalo bajo los mismos criterios del literal anterior.
13. (**Särndal et al., 1992, Ej. 3.1**) Suponga que se desea extraer una muestra Bernoulli de la población CO124, conformada por $N = 124$ países, con el fin de estimar el total de la variable *y: importaciones de 1983 en millones de dólares*, con un error estándar relativo del 10 %, usando (a) el π -estimador y (b) el estimador alternativo

$$\hat{t}_{alt} = N \frac{\sum_s y_k}{n_s} = N \bar{y}_s, \quad \text{con} \quad V_{BE}(\hat{t}_{alt}) \doteq N^2 \left(\frac{1}{n} - \frac{1}{N} \right) S_{yU}^2,$$

donde $n = N\pi = E(n_s)$ es el tamaño de muestra esperado. Usando como información auxiliar $\sum_U y_k \doteq 1,81 \times 10^6$ y $\sum_U y_k^2 \doteq 1,69 \times 10^{11}$, calcule los tamaños de muestra esperados necesarios en cada caso. Comente sus resultados. El error estándar relativo se define como $\sqrt{V(\hat{t})}/\hat{t}$.

14. (**Särndal et al., 1992, Ej. 3.2**) Usando $\pi = 0,1$, se extrajo una muestra Bernoulli de la población MU284 de municipios suecos ($N = 284$), con el fin de estimar los totales de las variables P85 (*población de 1985, en miles*) y RMT85 (*ingresos por impuestos municipales de 1985, en millones de coronas*). Se obtuvieron los siguientes resultados:

Variable	$\sum_s y_k$	$\sum_s y_k^2$
P85	564	15 790
RMT85	4 178	878 452

Calcule estimaciones insesgadas de los dos totales, así como las correspondientes estimaciones insesgadas de la varianza y los *cve*.

15. (**Särndal et al., 1992, Ej. 3.4**) En la población MU284 ($N = 284$), el coeficiente de variación de la variable CS82 (*número de escaños conservadores en el concejo municipal*) es $cv_{yU} = 0,543$. Determine el tamaño de muestra mínimo (esperado) necesario para estimar el total de CS82 de modo que el error estándar relativo del π -estimador, $\sqrt{V(\hat{t}_{y,\pi})}/\hat{t}_{y,\pi}$, no sea mayor al 10 % bajo:
- a. Muestreo aleatorio simple (M.A.S).
- b. Muestreo Bernoulli.
- c. ¿Cuál es el tamaño de muestra esperado requerido bajo muestreo Bernoulli si se usa el estimador alternativo $\hat{t}_{alt} = N \bar{y}_s$ (ver ejercicio 13) en lugar del π -estimador?
16. (**Särndal et al., 1992, Ej. 3.5**) Se extrajo una M.A.S de tamaño $n = 30$ de la población MU284 ($N = 284$) con el fin de estimar el total de la variable S82 (*número total de escaños en el concejo municipal*). Se calcularon los totales muestrales $\sum_s y_k = 1 424$ y $\sum_s y_k^2 = 70 758$. Calcule un intervalo de confianza aproximado del 95 % para el total de S82, es decir, para el número total de escaños en los concejos municipales.

17. Suponga que se tiene $U = \{1, 2, 3, 4, 5\}$ y que se conocen todos los valores de la variable de interés y las probabilidades de selección en cada extracción, dados por:

k	y_k	p_k
1	79	0,10
2	76	0,15
3	54	0,20
4	39	0,25
5	12	0,30

Para una muestra de tamaño $m = 3$ con reemplazo, calcule (en Excel):

- Todas las muestras posibles (muestras ordenadas).
 - Para cada muestra, determine la muestra no ordenada.
 - Para cada muestra, calcule la estimación de t_y usando como estimadores $\hat{t}_{y,MCR}$ y $\hat{t}_{y,\pi}$.
 - Determine el valor esperado, la varianza, la varianza estimada y el valor esperado de la varianza estimada para los dos estimadores.
 - Para cada muestra, calcule un intervalo de confianza del 90 %, 95 % y 99 % para los dos estimadores.
 - Determine la probabilidad de cobertura (confiabilidad) de cada uno de los intervalos hallados en el literal anterior.
 - Concluya.
18. (Särndal et al., 1992, Ej. 2.12) Se desea estimar el ingreso promedio por hogar, $\sum_U y_k/N$, para una población de $N = 200$ hogares. Para ello se usó un listado de las 600 personas que pertenecen a los 200 hogares, de la siguiente manera: se seleccionó una M.A.S con reemplazo de tamaño $m = 10$ personas, se identificaron los hogares de las personas seleccionadas y se recolectó la información sobre el ingreso promedio del hogar, y_k/x_k , donde y_k es el ingreso total del hogar en dólares y x_k es el número de personas en el hogar. Los resultados son:

Extracción	Ingreso promedio del hogar
i	y_{k_i}/x_{k_i}
1	7 000
2	8 000
3	6 000
4	5 000
5	9 000
6	4 000
7	7 000
8	8 000
9	4 000
10	2 000

Calcule una estimación del ingreso promedio por hogar basada en el estimador MCR (pwr) y halle el *cve* correspondiente. Concluya.

19. En un estudio de un producto se registró la calidad (1 = Alta, 2 = Media, 3 = Baja), el almacén donde se distribuye (1 = Almacén A, 2 = Almacén B) y la cantidad de productos vendidos semanalmente. Usando la información del archivo `data/Almacenes.xlsx`, complete el siguiente cuadro de salida del total de productos vendidos semanalmente bajo cada una de las siguientes tres estrategias: M.A.S($320, 150, \hat{t}_{y,\pi}$), Bernoulli($0,30, \hat{t}_{y,\pi}$) y MCR($1/320, \hat{t}_{y,MCR}$).

	Calidad			
	Alta	Media	Baja	Total
Almacén	$\hat{t}_y$ <i>cve</i>	$\hat{t}_y$ <i>cve</i>	$\hat{t}_y$ <i>cve</i>	$\hat{t}_y$ <i>cve</i>
A				
B				
Total				

20. Se entrevistaron 150 estudiantes y se registró el sexo (1 = Hombre, 2 = Mujer) y los conceptos a pagar para la inscripción (matrícula y sistematización). Usando el archivo `data/Estudiantes.xlsx`, complete el siguiente cuadro de salida suponiendo las estrategias: M.A.S(265, 150, $\hat{t}_{y,\pi}$), Bernoulli(0,25, $\hat{t}_{y,\pi}$) y MCR(1/265, $\hat{t}_{y,MCR}$).

Sexo	Matrícula	Sistematización	Total
	$\hat{t}_y$ <i>cve</i>	$\hat{t}_y$ <i>cve</i>	$\hat{t}_y$ <i>cve</i>
Hombre			
Mujer			
Total			

Para la población total ($N = 265$), estime además el promedio a pagar por estudiante para inscribirse a la Universidad, $\bar{y}_U = t_y/N$, y su *cve*.

21. En una manzana de un barrio con $N = 160$ personas adultas se entrevistó a 12 de ellas; se registró el sexo (1 = Femenino, 2 = Masculino), el grupo de edad al cual pertenece (1 = de 18 a 30 años, 2 = entre 30 y 45 años, 3 = mayores de 45 años) y se les preguntó por la cantidad de horas dedicadas a navegar por internet en la última semana. Usando el archivo `data/Dominios.xls`, estime el total de horas dedicadas a navegar por internet en el siguiente cuadro de salida, bajo las estrategias: M.A.S(160, 12, $\hat{t}_{y,\pi}$), Bernoulli(0,07, $\hat{t}_{y,\pi}$) y MCR(1/160, $\hat{t}_{y,MCR}$).

Sexo	Edad	M.A.S(160, 12)	Bernoulli(0,07)	MCR(1/160)
		$\hat{t}_{y,\pi}$ <i>cve</i>	$\hat{t}_{y,\pi}$ <i>cve</i>	$\hat{t}_{y,MCR}$ <i>cve</i>
Femenino	18-30			
	30-45			
	> 45			
	Total			
Masculino	18-30			
	30-45			
	> 45			
	Total			
Total	18-30			
	30-45			
	> 45			
	Total			

Bibliografía

Lohr, S. L. (2022). *Sampling: Design and Analysis* (3rd ed.). Boca Raton, FL: CRC Press.

Särndal, C.-E., Swensson, B. y Wretman, J. (1992). *Model Assisted Survey Sampling*. Springer Series in Statistics. New York: Springer-Verlag.