Universidad Nacional de Colombia

Departamento de Estadística

Taller 2

2018631 Teoría de muestreo; 2020928 Muestreo estadístico aplicado; 2016369 Muestreo estadístico

Profesor: Giovany Babativa-Márquez, PhD.
Temas: muestreo sistemático, muestreo Poisson, diseños πPT (Lahiri, Brewer y Sunter), muestreo estratificado y afijación, muestreo de conglomerados ($MASC$) y muestreo bietápico.
Datos: los archivos referenciados se encuentran en la carpeta `data` del repositorio. Los archivos con municipios y manzanas contienen cifras reales del DANE; las demás bases y tablas son simuladas o ilustrativas, y así se indica en cada caso.
Paquetes de R: `survey`, `srvyr`, `TeachingSampling`, `stratification`, `samplesize4surveys`, `sf` y `tmap`. Declare siempre `weights` en los objetos de diseño. Para poder comparar resultados, use `set.seed(2026)` antes de cada selección, salvo en la Tarea final.
Entrega: la Tarea final (ejercicio 26) se entrega en Moodle.

Muestreo sistemático

1. **(Särndal et al., 1992, Ej. 3.10)** Considere la población MU280, es decir, los municipios suecos de MU284 sin los cuatro más grandes. Se usa muestreo sistemático con intervalo $a = 10$ para estimar el total de la variable RMT85 bajo tres ordenamientos de la población: O_1, el orden del Apéndice del libro; O_2, de menor a mayor según S82; y O_3, de menor a mayor según ME84. Para cada ordenamiento hay 10 muestras sistemáticas posibles, con los siguientes totales de RMT85:

Muestra	1	2	3	4	5	6	7	8	9	10
O_1	4.826	4.938	4.531	7.821	7.051	5.235	5.592	4.432	3.037	4.411
O_2	4.507	5.006	5.503	5.736	6.149	5.673	5.047	4.538	4.499	5.216
O_3	4.633	4.770	5.036	4.873	5.182	5.504	5.222	5.443	5.649	5.562

   a. Calcule el error estándar del π-estimador para cada ordenamiento.
   b. La varianza poblacional de RMT85 es $S^2_{yU} = 35.932$. Calcule el error estándar del π-estimador bajo M.A.S con $n = 28$.
   c. Calcule la medida de homogeneidad δ para los tres ordenamientos y compárela con $\delta_{\text{mín}} = -(a-1)/(N-a)$. ¿Qué ordenamiento recomienda y por qué?

2. **(Särndal et al., 1992, Ej. 3.11)** Para estimar el total de la variable P83 ($= y$) en la población CO124 (124 países), se realizó un muestreo sistemático con dos arranques aleatorios. La población se ordenó de menor a mayor según P80 y se extrajo un M.A.S de dos enteros entre 1, 2, 3 y 4. Salieron 2 y 3: los elementos ordenados 2, 6, 10, ..., 122 forman la primera parte de la muestra (s_1) y los elementos 3, 7, 11, ..., 123, la segunda (s_2). Se obtuvo $\sum_{s_1} y_k = 825{,}7$ y $\sum_{s_2} y_k = 1.320{,}4$. Calcule una estimación insesgada del total de P83, una estimación insesgada de su varianza y el *cve*.

3. *[Excel y R; datos reales]* El archivo `data/Taller2_Municipios2026.xlsx` contiene la población proyectada por el DANE para 2026 en cada municipio de Colombia. Tome los $N = 64$ municipios de Nariño y suponga que se quiere estimar su población total con una muestra sistemática de $n = 8$ municipios ($a = 8$). Como se conoce toda la población, puede calcular exactamente las propiedades del diseño. Trabaje con dos ordenamientos: (i) el orden del código DIVIPOLA y (ii) de mayor a menor población.

   a. Liste las 8 muestras sistemáticas posibles en cada ordenamiento y calcule su total.
   b. Construya la tabla ANOVA (SCE, SCD y SCT) y verifique que $SCT = SCE + SCD$ y que $V_{SY}(\widehat{t}_\pi) = N \cdot SCE$.
   c. Calcule el *cve*, δ y $deff(SY, \widehat{t}_\pi)$ en cada ordenamiento. ¿Por qué el ordenamiento cambia la precisión si el tamaño de muestra es el mismo?

d. ¿Por qué el *cve* sigue siendo tan grande en ambos casos? Observe qué ocurre con Pasto y proponga una mejora del diseño.

Muestreo Poisson

4. *[Excel y R; datos reales]* Con los $N = 123$ municipios de Boyacá en `data/Taller2_Municipios2026.xlsx`, considere un muestreo Poisson de tamaño esperado 20, con $\pi_k \propto x_k$, donde x_k son los hogares de 2018 (`hogares_2018`). Se quieren estimar dos totales: y_1, los hogares de 2026 (`hogares_2026`), y y_2, la población rural (`poblacion_rural_2025`).

   a. Calcule los π_k. Los municipios con $\pi_k \geq 1$ pasan a inclusión forzosa ($\pi_k = 1$) y se recalculan los demás hasta que ninguno supere 1. ¿Cuántos quedan con inclusión forzosa? Verifique $E_{PO}(n_s) = 20$ y calcule $V_{PO}(n_s)$.

   b. Calcule $V_{PO}(\widehat{t}_\pi)$ y el *cve* para y_1 y y_2. Compárelos con Bernoulli ($\pi = 20/123$) y con M.A.S$(123, 20)$. ¿Para cuál variable conviene usar x_k y para cuál no? Explique por qué.

   c. Seleccione la muestra con `S.PO(N, pik)` de `TeachingSampling`. Para ambas variables calcule $\widehat{t}_\pi$, $\widehat{V}_{PO}(\widehat{t}_\pi)$ y $\widehat{t}_{alt} = N \sum_s \breve{y}_k / \widehat{N}$, y compárelos con los totales reales. ¿Qué relación observa entre n_s, $E_{PO}(n_s)$ y el error de $\widehat{t}_\pi$?

Diseños πPT: Lahiri, Brewer y Sunter

5. *[Excel; datos reales]* La siguiente tabla presenta los 7 municipios de Arauca, con su población en 2026 en miles (x_k) y sus hogares en 2026 (y_k).

k	Municipio	x_k	y_k
1	Arauca	102,4	35.640
2	Arauquita	64,8	19.516
3	Cravo Norte	4,7	1.628
4	Fortul	24,6	7.586
5	Puerto Rondón	5,3	1.860
6	Saravena	66,3	26.608
7	Tame	55,2	18.205

   a. **Lahiri.** Con $M = 103$, aplique el método a los siguientes pares (k_r, ε_r): (3; 0,41), (6; 0,91) y (2; 0,33). ¿Qué municipio se selecciona? ¿Cuántos intentos se esperan en promedio por selección?

   b. **Brewer.** Para $n = 2$, verifique la condición $x_k < t_x/2$ y calcule c_k, p_k y π_k para todos los municipios.

   c. Suponga que se seleccionó $s = \{\text{Arauca, Fortul}\}$. Calcule π_{kl}, $\widehat{t}_\pi$, el estimador de Sen-Yates-Grundy y el *cve*.

   d. Construya las 21 muestras posibles con su $p(s) = \pi_{kl}$ y su $\widehat{t}_\pi$. Verifique que $\sum_s p(s) = 1$ y $E(\widehat{t}_\pi) = t_y$, y calcule $V(\widehat{t}_\pi)$ exacta. Compare su *cve* con el de M.A.S$(7, 2)$.

6. *[R; `TeachingSampling`; datos reales]* **Selección por el método de Sunter.** Se quiere seleccionar una muestra de $n = 15$ de los $N = 87$ municipios de Santander, con x_k la población de 2026. La función `S.piPS(n, x)` aplica la regla de Sunter.

   a. Calcule $\pi_k = n\, x_k / t_x$. ¿Qué municipios deben ser de inclusión forzosa? Sepárelos y recalcule para los demás, hasta que ninguno alcance 1. ¿Con qué n queda la parte πPT?

   b. Seleccione la parte πPT con `S.piPS()` y liste los municipios con su π_k y d_k.

   c. Estime los hogares de 2026 y la población rural del departamento: total de los forzosos más el π-estimador de la parte πPT. Para el *cve*, use la aproximación de varianza con reemplazo: declare `svydesign(ids = ~1, weights = ~fex, data = muestra)`, sin `fpc`, con `fex` $= 1/\pi_k$.

   d. Repita 2.000 veces la selección de la parte πPT y la de un M.A.S del mismo tamaño. Compare la media y la desviación estándar de los estimadores con los totales reales. ¿En cuál variable gana más πPT? ¿Por qué?

Muestreo estratificado y afijación

7. **(Särndal et al., 1992, Ej. 3.15)** Para estimar el total de SS82 ($= y$), la población MU284 se dividió en cuatro estratos según S82 ($= x$), el número de escaños:

Escaños	N_h	$\sum_{U_h} x_k$	$\sum_{U_h} x_k^2$	$\sum_{U_h} y_k$	$\sum_{U_h} y_k^2$
31–40	44	1.518	52.764	756	13.784
41–50	168	7.524	339.344	3.383	72.223
51–70	56	3.198	184.168	1.545	44.529
71 o más	16	1.260	100.016	617	24.137

   a. Con *ESTMAS* y el π-estimador $\sum_h N_h \bar{y}_{s_h}$, afije $n = 40$ según: (1) afijación proporcional, (2) afijación x-óptima y (3) afijación proporcional al total de x.

   b. Compare las tres estrategias con M.A.S de $n = 40$ y el π-estimador $N\bar{y}_s$: calcule las cuatro varianzas.

   c. Se escogió la afijación x-óptima y se obtuvieron los siguientes datos muestrales. Estime el total de SS82, su varianza y el *cve*.

Escaños	$\sum_{s_h} y_k$	$\sum_{s_h} y_k^2$
31–40	89	1.647
41–50	441	9.735
51–70	280	8.294
71 o más	152	5.794

8. **(Särndal et al., 1992, Ej. 3.16)** Considere el total de P83 ($= y$) en la población CO124 y un diseño *ESTMAS* con dos estratos: el estrato 1, con los 105 países más pequeños según P80, y el estrato 2, con los 19 más grandes. En el estrato 1 se extrae un M.A.S de tamaño 11 y el estrato 2 es de inclusión forzosa. Se tienen los siguientes datos:

Estrato h	$\sum_{U_h} y_k$	$\sum_{U_h} y_k^2$
1	1.098,9	21.855,05
2	3.445,9	1.822.736,83

   a. Calcule la varianza del π-estimador del total.

   b. Si se usara M.A.S con el π-estimador $N\bar{y}_s$, ¿qué tamaño de muestra se necesitaría para lograr la misma varianza?

9. **(Lohr, 2022, Ej. 3.6)** Una ciudad tiene 90.000 viviendas: 35.000 casas, 45.000 apartamentos y 10.000 condominios.

   a. Se cree que el consumo medio de electricidad de las casas es cerca del doble que el de apartamentos o condominios, y que la desviación estándar es proporcional a la media: $S_1 = 2S_2 = 2S_3$. ¿Cómo afijaría una muestra estratificada de 900 viviendas para estimar el consumo medio?

   b. Con afijación proporcional se quiere estimar la proporción de hogares que ahorran energía. Si lo hacen el 45 % de las casas, el 25 % de los apartamentos y el 3 % de los condominios, ¿cuál es la proporción poblacional p? ¿Cuánto se gana frente a M.A.S, es decir, cuánto vale $V_{prop}(\widehat{p})/V_{MAS}(\widehat{p})$?

10. **(Lohr, 2022, Ej. 3.29)** Una ciudad ficticia hace un conteo anual de personas sin hogar, con 4 divisiones geográficas y áreas de alta y baja densidad. y_{hj} es el número de personas sin refugio encontradas en el área j del estrato h.

Estrato h	1	2	3	4	5	6	7	8
División	1	2	3	4	1	2	3	4
Densidad	Alta	Alta	Alta	Alta	Baja	Baja	Baja	Baja
N_h	12	8	4	16	384	192	240	144
n_h	12	8	4	16	24	12	15	9
$\bar{y}_h$	2,167	3,500	5,750	9,188	0,375	0,167	0,133	0,444
s_h^2	3,424	2,571	0,250	12,829	0,332	0,152	0,124	1,028

a. Estime el total de personas sin hogar en la ciudad, con un IC del 95 %.
b. ¿Cuánto cambia el resultado si no usa la corrección por población finita?
c. El IC recoge el error de muestreo. ¿Cuáles son algunas fuentes de error ajeno al muestreo?

11. **(Lohr, 2022, Ej. 3.30)** Con los datos del ejercicio anterior, compare cuatro diseños según dos metas: (1) estimar con precisión el total y (2) incluir en la muestra la mayor cantidad posible de personas sin refugio.

- Diseño 1: afijación proporcional.
- Diseño 2: afijación de Neyman para estimar t.
- Diseño 3: censo en los estratos de alta densidad; el resto, con Neyman en los de baja densidad.
- Diseño 4: dos áreas por estrato; el resto de la muestra se asigna tomando todas las áreas del estrato con mayor $\bar{y}_{U_h}$, luego las del segundo, y así sucesivamente.

a. Halle la afijación de 100 áreas en cada diseño, con al menos dos áreas por estrato. Use $\bar{y}_h$ y s_h^2 como aproximaciones de $\bar{y}_{U_h}$ y S_h^2.
b. Calcule la $V(\widehat{t})$ anticipada y el valor anticipado de $\sum_h \sum_{s_h} y_{hj}$.
c. ¿Qué diseño usaría si prioriza la meta 1? ¿La meta 2? ¿Y si ambas son igual de importantes?

12. *[Excel; tabla de resumen, cifras ilustrativas]* Una empresa de acueducto quiere estimar el consumo mensual de agua (m^3) de los hogares de Cali, y la proporción de hogares que reciben subsidio. Estratificó por grupo de estrato socioeconómico y seleccionó un M.A.S en cada grupo:

Grupo	N_h	n_h	$\bar{y}_{s_h}$	s_{y_h}	$\widehat{p}_h$
Estratos 1 y 2	320.000	150	11,4	4,8	0,62
Estratos 3 y 4	260.000	150	15,2	6,1	0,41
Estratos 5 y 6	60.000	100	24,6	12,3	0,18

a. Estime el consumo total y el consumo medio por hogar, con su *cve* e $IC_{95\,\%}$.
b. Estime el total y la proporción de hogares con subsidio, con su *cve*.
c. Con $n = 400$ y usando estas cifras como información previa, afije según: igual, proporcional, Neyman y potencia con $\alpha = 0{,}5$ sobre $\widehat{t}_{yh} = N_h \bar{y}_{s_h}$. Calcule el *cve* anticipado del total en cada caso y compare.
d. Si cada encuesta cuesta \$16.000, \$25.000 y \$49.000 en los grupos 1, 2 y 3, y el presupuesto es de \$10 millones, halle la afijación óptima. Compárela con la proporcional del mismo presupuesto.

13. *[Excel y R; `TeachingSampling`; datos reales]* **Selección** *ESTMAS*. Las 4.528 manzanas con viviendas de Bucaramanga en el CNPV 2018 están en `data/Taller2_ManzanasBmanga.xlsx`, con las variables `manzana`, `seccion`, `comuna`, `sector`, `nivel` (estrato de energía predominante), `viviendas`, `hogares`, `personas` e `internet` (viviendas con internet). Como es un censo, puede comparar sus estimaciones con los valores reales. Se estratifica por `nivel` y se toman $n = 300$ manzanas.

a. Construya una tabla de resumen por estrato con N_h, t_{yh} y S_{y_h} para `internet`. Calcule SCT, SCE y SCD. ¿Qué porcentaje de la variación explica la estratificación?
b. Afije $n = 300$ de forma proporcional, por Neyman y por potencia con $\alpha = 0{,}6$. Calcule el *cve* de cada una y el de M.A.S.
c. Con la afijación de Neyman (redondeada), ordene el marco por `nivel` y seleccione la muestra con `S.STSI(S, Nh, nh)`. Declare el objeto de diseño con `strata`, `weights` y `fpc`.
d. Complete en Excel y en R el siguiente cuadro de salida y compare con los valores reales. ¿Por qué los *cve* de los corregimientos son tan grandes?

Sector	Viviendas con internet $\widehat{t}_y$	*cve*	Personas $\widehat{t}_y$	*cve*
Comunas 1 a 5				
Comunas 6 a 10				
Comunas 11 a 17				
Corregimientos				
Total				

Muestreo de conglomerados

14. **(Särndal et al., 1992, Ej. 4.1)** Para estimar el total de la variable SS82 ($= y$) en la población MU284, se extrajo una muestra $MASC$ de tamaño $n_I = 20$ de los $N_I = 50$ conglomerados del Apéndice C. Se obtuvo $\sum_{s_I} t_i = 2.450$ y $\sum_{s_I} t_i^2 = 327.296$. Calcule una estimación insesgada del total de SS82, una estimación insesgada de su varianza y el *cve*.

15. **(Särndal et al., 1992, Ej. 4.4)** Considere la población MU284 y la variable REV84. Se quiere estimar el total con muestreo de conglomerados, usando los 50 conglomerados del Apéndice C. Con $MASC$ y $n_I = 25$, la varianza del π-estimador es $8{,}5 \cdot 10^9$. Compárela con la varianza bajo un diseño estratificado con $MASC$ en cada estrato, si los 50 conglomerados se dividen en cuatro estratos según TP75. S_{th} es la desviación estándar de los totales t_i en el estrato h:

TP75	N_{Ih}	S_{th}	n_{Ih}
0–75	16	2.268	4
75–175	13	4.729	8
175–275	17	4.848	9
275 o más	4	22.420	4
	50		25

16. **(Lohr, 2022, Ej. 5.1)** El concejo de una ciudad pequeña quiere conocer la proporción de votantes que se oponen a un incinerador de basuras a las afueras de la ciudad. Seleccionan al azar 100 números residenciales de los 3.000 del directorio telefónico. En cada residencia preguntan (a) el total de votantes y (b) el número de votantes que se oponen. Se encuestó a 157 votantes, de los cuales 23 no respondieron. De los otros 134, 112 se oponen, y el concejo estima $\widehat{p} = 112/134 = 0{,}83582$, con $\widehat{V}(\widehat{p}) = 0{,}83582(1 - 0{,}83582)/134 = 0{,}00102$. ¿Son válidas estas estimaciones? ¿Por qué?

17. **(Lohr, 2022, Ej. 5.11)** Una firma contable quiere estimar la tasa de error en una auditoría. La población tiene 828 reclamaciones y la firma audita un M.A.S de 85. En cada una se revisan 215 campos: una reclamación tiene errores en 4 campos, una tiene 3 errores, 4 tienen 2 errores, 22 tienen 1 error y las otras 57 no tienen errores.

    a. Tomando las reclamaciones como conglomerados y los campos como elementos, estime la tasa de error (errores promedio por campo), con su error estándar.

    b. Estime el total de errores en las 828 reclamaciones, con su error estándar.

    c. Si se hubiera tomado un M.A.S de $85 \times 215 = 18.275$ de los 178.020 campos, con la misma tasa de error estimada, ¿cuál sería $\widehat{V}(\widehat{p}_{MAS})$? Compárela con la varianza de (a).

18. *[Excel; tabla de resumen, cifras ilustrativas]* Para conocer la pesca artesanal en la Ciénaga Grande de Santa Marta, se seleccionó un M.A.S de $n_I = 7$ de los $N_I = 42$ caseríos y se censó a todos sus pescadores, con y_k los kilogramos capturados en el mes. Se sabe que en los 42 caseríos hay $N = 900$ pescadores.

Caserío	N_i	t_i	$\sum_{U_i}(y_k - \bar{y}_{U_i})^2$
A	18	5.760	61.200
B	26	4.940	62.500
C	12	1.140	9.900
D	33	9.240	115.200
E	21	7.350	98.000
F	15	2.100	17.150
G	29	6.090	70.000

    a. Estime la captura total, con su *cve* e $IC_{95\,\%}$.

    b. Estime N con $\widehat{N} = N_I \bar{N}_{s_I}$ y compárelo con el valor conocido. Estime la captura media por pescador con $\widehat{t}_\pi / N$ y su *cve*.

c. Con los 7 caseríos, calcule SCE, SCD y SCT, y una aproximación de δ y del $deff$. ¿Los caseríos son homogéneos o heterogéneos por dentro? ¿Qué implica para el diseño?

d. ¿Cómo aprovecharía esta información si pudiera clasificar los 42 caseríos antes de seleccionar?

19. *[Excel y R; `TeachingSampling`; datos reales]* **Selección $MASC$.** Con el archivo del ejercicio 13, suponga que las secciones censales (`seccion`) son los conglomerados: $N_I = 311$. Se quiere una muestra de cerca de 300 manzanas.

a. Construya la tabla con N_i y t_i para `internet`. Calcule SCT, SCE, SCD, δ y $\bar{N}$. ¿Cuántas secciones n_I se necesitan para esperar cerca de 300 manzanas?

b. Calcule $V_{MASC}(\widehat{t}_\pi)$, el cve y el $deff$ exacto frente a M.A.S con $n_I\bar{N}$ manzanas. Compárelo con la aproximación $1 + (\bar{N} - 1)\delta$. ¿Por qué difieren?

c. Seleccione las secciones con `S.SI(NI, nI)`, recupere todas sus manzanas y declare el objeto de diseño con `ids`, `weights` y `fpc`. Estime el total de viviendas con internet y de personas, con su cve. Compruebe el resultado en Excel usando los t_i.

d. Compare con $ESTMAS$ (ejercicio 13) y con M.A.S. Si $MASC$ es menos preciso, ¿en qué situación real lo preferiría?

Muestreo bietápico

20. **(Särndal et al., 1992, Ej. 4.7, con los datos del Ej. 8.1)** Un campo se divide en $N_I = 10$ áreas. Se quiere estimar el tamaño medio de las plantas, $\bar{y}_U = \sum_U y_k/N$, con $N = 78$ conocido. Se tiene el tamaño de todas las plantas para comparar estrategias:

Área i	N_i	n_i	Tamaño de las plantas, y_k, $k \in U_i$
1	11	4	12 11 12 10 13 14 11 12 13 14 14
2	6	2	10 9 7 9 8 10
3	5	2	6 5 7 5 4
4	7	2	7 8 7 7 6 8 7
5	11	4	10 13 13 12 12 14 11 12 13 14 14
6	10	3	14 15 13 12 13 14 16 12 16 15
7	5	2	6 7 6 5 4
8	7	2	9 10 8 9 9 10 9
9	6	2	7 10 8 9 9 10
10	10	3	12 13 12 13 12 12 16 14 13 15

Estrategia 1: M.A.S de $n_I = 5$ de las 10 áreas y, en cada área seleccionada, M.A.S de n_i plantas, con $\widehat{\bar{y}}_U = \widehat{t}_\pi/N$. **Estrategia 3:** en la primera etapa, $ESTMAS$ con dos estratos: $U_{I1} = \{1, 5, 6, 10\}$ (áreas grandes), con $n_{I1} = 3$, y $U_{I2} = \{2, 3, 4, 7, 8, 9\}$ (áreas pequeñas), con $n_{I2} = 2$; la segunda etapa y el estimador son iguales. Calcule los dos componentes de la varianza y la varianza total en cada estrategia. ¿Mejora la estratificación las estimaciones? ¿En cuál componente?

21. **(Särndal et al., 1992, Ej. 4.8)** Se quiere estimar el total de CS82 (= y) en la población MU284. Se usa muestreo bietápico con M.A.S de $n_I = 5$ de los $N_I = 50$ conglomerados del Apéndice C y, en cada uno, un M.A.S de $n_i = 2$ elementos:

i	N_i	k	y_k
11	6	61	8
		58	10
5	5	24	13
		23	12
20	5	113	11
		112	8
48	5	266	2
		270	7
14	7	77	16
		81	10

a. Calcule una estimación insesgada del total de CS82.

b. Calcule estimaciones insesgadas de V_{UPM}, V_{USM} y $V = V_{UPM} + V_{USM}$, y el *cve*.

c. Calcule las varianzas simplificadas $\widehat{V}^{**} = \dfrac{N_I^2}{n_I(n_I-1)} \sum_{s_I} \left(\widehat{t}_{i\pi} - \sum_{s_I} \widehat{t}_{i\pi}/n_I\right)^2$ y $\widehat{V}^{*} = (1 - n_I/N_I)\,\widehat{V}^{**}$, con sus *cve*. Comente sus conclusiones.

22. **(Särndal et al., 1992, Ej. 4.10)** Para estimar el porcentaje de perceptores de ingresos en Suecia, se usó un diseño bietápico. En la primera etapa, una muestra Poisson de municipios entre los 284, con probabilidad de inclusión proporcional a la población y tamaño esperado 10. En la segunda, un M.A.S de 100 personas en cada municipio seleccionado. La población total es de 8.327.484 personas.

Municipio	Población	Perceptores	Municipio	Población	Perceptores
10	59.665	72	129	27.784	74
19	26.052	83	133	12.639	75
86	29.885	76	157	30.355	75
89	15.151	74	160	13.408	80
101	48.839	76	236	87.621	79
114	230.381	81	242	18.600	75
			266	8.664	78
			283	9.969	75

a. Calcule una estimación insesgada del porcentaje de perceptores de ingresos en la población.

b. Calcule una estimación insesgada de la varianza del estimador.

c. ¿Es razonable el resultado de (a)? Compare n_s con su valor esperado y explique qué ocurre. Proponga un estimador alternativo con los mismos datos.

23. **(Särndal et al., 1992, Ej. 4.12)** Un estudiante tiene 401 libros y quiere estimar el total de palabras de su colección con un diseño de **tres etapas**. Etapa 1: M.A.S de 5 de los 401 libros. Etapa 2: M.A.S de dos páginas en cada libro seleccionado. Etapa 3: en cada página, muestreo sistemático de líneas con dos arranques: un M.A.S de dos de los primeros 10 enteros, r y r', y se toman las líneas $r, r+10, r+20, \ldots$ y $r', r'+10, r'+20, \ldots$ Luego cuenta las palabras de cada línea seleccionada.

Libro seleccionado	Páginas del libro	Páginas seleccionadas	Palabras en la muestra sistemática 1	2
81	178	36	13	11
		82	18	21
186	128	94	29	28
		117	29	21
195	278	61	22	24
		212	25	27
288	243	99	19	15
		111	20	24
387	191	71	34	29
		178	34	35

a. Calcule una estimación insesgada del total de palabras.

b. Calcule una estimación insesgada de la varianza del estimador y el *cve*.

c. Calcule las dos varianzas simplificadas del ejercicio 21.

d. Calcule estimaciones insesgadas de V_{UPM}, V_{USM} y V_{UTM}.

24. **(Lohr, 2022, Ej. 5.7)** Una firma de mercadeo tomó un M.A.S de 6 de las 45 ciudades de una región y, en cada ciudad i, un M.A.S de m_i de sus M_i supermercados. Se registraron las cajas vendidas en marzo de un dulce nuevo:

Ciudad	M_i	m_i	Cajas vendidas
1	52	10	146, 180, 251, 152, 72, 181, 171, 361, 73, 186
2	19	4	99, 101, 52, 121
3	37	7	199, 179, 98, 63, 126, 87, 62
4	39	8	226, 129, 57, 46, 86, 43, 85, 165
5	8	2	12, 23
6	14	3	87, 43, 59

Calcule el factor de expansión de cada supermercado de la muestra. Estime el total de cajas vendidas en la región, con su error estándar. ¿El diseño es autoponderado?

25. *[Excel y R; datos simulados]* Para evaluar la cobertura de acueducto veredal en una zona rural de Nariño, se seleccionó un M.A.S de $n_I = 8$ de las $N_I = 60$ veredas y, en cada vereda, un M.A.S de n_i de sus N_i hogares. El archivo `data/Taller2_AcueductoNarino.xlsx` contiene `vereda`, `Ni`, `ni`, `hogar`, `acueducto` (1 si tiene, 0 si no) y `gasto_agua` (miles de pesos al mes).

    a. En Excel, construya la tabla por vereda con N_i, n_i, $\widehat{t}_{i\pi} = N_i \bar{y}_{s_i}$ y $S^2_{ys_i}$ para `acueducto` y `gasto_agua`.

    b. Estime el total de hogares con acueducto y el gasto total, con $\widehat{V}_{UPM}$, $\widehat{V}_{USM}$ y el *cve*. ¿Qué etapa aporta más a la varianza?

    c. Calcule $\widehat{N}$. Si se conoce que $N = 5.000$, estime la proporción de hogares con acueducto con $\widehat{t}_\pi / N$, con su *cve* e $IC_{95\,\%}$.

    d. Verifique en R, calculando `fex` $= (N_I/n_I)(N_i/n_i)$:

```
dis_bi <- svydesign(ids = ~vereda + hogar, weights = ~fex, fpc = ~NI + Ni, data = encuesta)
```

Tarea final: diseño de una encuesta nacional con el MGN

26. **(Tarea para entregar en Moodle. Se desarrolla al terminar muestreo bietápico.)** Diseñe y seleccione la muestra de una encuesta nacional en zonas urbanas. Las unidades primarias de muestreo (UPM) son los municipios y las unidades secundarias (USM), las manzanas del Marco Geoestadístico Nacional (MGN). Use como semilla los últimos 6 dígitos de su documento de identidad.

    Datos. (1) Población: `data/PoblacionMunicipios2026.xlsx`. (2) Manzanas: capa urbana `MGN_URB_MANZANA` del MGN 2021, disponible en el Geoportal del DANE. Incluye cabeceras y centros poblados, y no use las capas rurales. (3) Viviendas por manzana: el campo `TVIVIENDA` del CNPV 2018, en el servicio `Serv_CapaManzanaInt_2018` del Geoportal.

    a. **Estratificación administrativa.** Agrupe los departamentos en las siguientes 6 regiones. Bogotá funciona como una región y ninguna concentra menos del 11 % de la población:

Región	Departamentos
Bogotá D.C.	Bogotá D.C.
Caribe	Atlántico, Bolívar, Cesar, Córdoba, La Guajira, Magdalena, San Andrés y Sucre
Centro Oriente	Boyacá, Cundinamarca, Norte de Santander y Santander
Antioquia y Eje Cafetero	Antioquia, Caldas, Quindío y Risaralda
Pacífico	Cauca, Chocó, Nariño y Valle del Cauca
Centro Sur, Llanos y Amazonía	Amazonas, Arauca, Caquetá, Casanare, Guainía, Guaviare, Huila, Meta, Putumayo, Tolima, Vaupés y Vichada

    b. **Estratos de tamaño.** En las 5 regiones distintas de Bogotá, use `strata.LH` sobre la población para formar 4 estratos de municipios: inclusión forzosa (IF), grandes, medianos y pequeños. Bogotá tiene un solo municipio, de modo que es de inclusión forzosa y no se le aplica `strata.LH`:

```
strata.LH(x, CV = 0.04, Ls = 4, takeall = 1, algo = "Kozak")
```

    c. **Número de UPM.** Use los tamaños n_h que entrega `strata.LH`, garantizando al menos 2 municipios por estrato dentro de cada región. Presente una tabla con N_h y n_h por región y estrato. ¿Cuántos municipios tiene la muestra?

d. **Tamaño de muestra.** Calcule el número de encuestas por región para garantizar un margen de error máximo de 4,8 puntos porcentuales, con 95 % de confianza, $P = 0{,}5$ y $DEFF = 2{,}0$. Puede usar `samplesize4surveys::ss4p()`. ¿Cuál es el total nacional?

e. **Afijación a los estratos.** En cada región r, afije la muestra con potencia $\alpha = 0{,}6$ sobre el total poblacional del estrato:

$$n_{rh} = n_r \, \frac{t_{rh}^{0,6}}{\sum_h t_{rh}^{0,6}}.$$

En Bogotá, toda la muestra de la región queda en su único estrato.

f. **Selección de UPM.** Con `TeachingSampling`, seleccione los municipios: todos los IF ($\pi_{Ii} = 1$), πPT con `S.piPS()` en grandes y medianos, y M.A.S con `S.SI()` en pequeños. Verifique que $\sum_{s_I} N_i/\pi_{Ii}$ se acerca a la población de cada región.

g. **Afijación a los municipios.** Se propone repartir la muestra del estrato así:

$$n_{hi} = n_{rh} \, \frac{N_i/\pi_{Ii}}{\sum_{s_{Ih}} N_j/\pi_{Ij}}.$$

Muestre que con esta regla $\pi_{Ii}\, n_{hi}/N_i$ es constante dentro del estrato, de modo que el diseño es autoponderado en cada estrato. ¿A qué se reduce n_{hi} en los estratos πPT? ¿Y en los de IF y M.A.S?

h. **Número de manzanas.** Con un tamaño fijo de **4 encuestas por manzana**, calcule $m_i = \text{máx}\{4, \lceil n_{hi}/4 \rceil\}$, es decir, al menos 4 manzanas por municipio. Construya el marco de manzanas de cada municipio seleccionado, con las que tengan al menos 4 viviendas en el CNPV 2018. Reporte cuántas manzanas y viviendas quedan por fuera y comente esta limitación de cobertura. Si $m_i > M_i$, seleccione todas las manzanas y reparta el excedente entre los demás municipios del mismo estrato; esto incluye municipios sin manzanas elegibles, como algunas áreas no municipalizadas.

i. **Selección de USM.** En cada municipio, seleccione m_i manzanas: πPT según las viviendas en los estratos IF, grandes y medianos, y M.A.S en pequeños. Las manzanas con $\pi \geq 1$ pasan a inclusión forzosa dentro del municipio.

j. **Factores de expansión.** Calcule, para cada manzana j del municipio i, $\pi_k = \pi_{Ii}\, \pi_{j|i}\, (4/V_j)$ y $d_k = 1/\pi_k$, con V_j las viviendas de la manzana. Resuma d_k por estrato. Si $\pi_{j|i} \propto V_j$, ¿por qué d_k varía tan poco dentro de un municipio?

k. **Mapa.** Con `tmap` v4, proyecte en un mapa html los **polígonos** de las manzanas seleccionadas. Agregue los centroides, porque a escala nacional las manzanas casi no se ven, y un *popup* con región, departamento, municipio, estrato y d_k:

```
manzanas <- st_read("MGN_URB_MANZANA.shp",
                    query = "SELECT * FROM MGN_URB_MANZANA WHERE COD_MPIO IN (...)")
tmap_mode("view")
mapa <- tm_shape(seleccion) + tm_polygons(fill = "estrato") +
  tm_shape(st_centroid(seleccion)) + tm_dots(fill = "estrato", size = 0.4)
tmap_save(mapa, "mapa_muestra.html", selfcontained = TRUE)
```

Entregables en Moodle: (1) el código en R, reproducible y comentado; (2) el mapa de salida en `.html`; y (3) un archivo `.xlsx` con tres hojas: estratos, municipios seleccionados y manzanas seleccionadas con sus probabilidades y factores de expansión.

Bibliografía

Lohr, S. L. (2022). *Sampling: Design and Analysis* (3rd ed.). Boca Raton, FL: CRC Press.

Särndal, C.-E., Swensson, B. y Wretman, J. (1992). *Model Assisted Survey Sampling*. Springer Series in Statistics. New York: Springer-Verlag.